

## Klasifikasi MIT-BIH Arrhythmia Database Metode Random Forest dan CNN dengan Model ResNet-50: A *Systematic Literature Review*

M. Rizky<sup>a</sup>, Roni Andarsyah<sup>b</sup>

<sup>a</sup>Program Studi D4 Teknik Informatika, Universitas Logistik & Bisnis Internasional, 1194021@std.poltekpos.ac.id

<sup>b</sup>Program Studi D4 Teknik Informatika, Universitas Logistik & Bisnis Internasional, roniandarsyah@ulbi.ac.id

Submitted: 12-05-2023, Reviewed: 24-05-2023, Accepted 27-06-2023

<https://doi.org/10.47233/jteksis.v5i3.825>

### Abstract

Although Machine Learning and Deep Learning technologies have been widely used and have shown high accuracy in many applications, including in the health field, their application in early detection of heart disease still has room for improvement. Further research is needed to enhance the accuracy and efficiency of this process. This study aims to understand and improve the process of ECG signal extraction and classification based on Machine Learning and Deep Learning. Essentially, this research aims to evaluate and compare various models, focusing on the Random Forest and Convolutional Neural Networks (CNN) models. The study reviews several related researches, especially those focusing on the process of extraction and classification of ECG signals using Machine Learning and Deep Learning. After extraction and classification of data, an evaluation and comparison process is conducted to determine the best performing model. From the research conducted, it was found that Machine Learning methods generally show an accuracy rate between 97.02% - 99.66%, with the Random Forest method having an accuracy of 97.02%. Meanwhile, the CNN method shows a higher accuracy rate, which is between 98.75% - 100%. Thus, this research confirms the superiority of CNN in this classification process, and shows potential for further use in early detection of heart disease.

**Keywords:** Machine Learning, Deep Learning, Extraction, ECG, Classification

### Abstrak

Meski teknologi *Machine Learning* dan *Deep Learning* sudah digunakan secara luas dan menunjukkan tingkat akurasi yang tinggi dalam banyak aplikasi, termasuk di bidang kesehatan, aplikasi dalam deteksi dini penyakit jantung masih memiliki ruang untuk peningkatan. Diperlukan penelitian lebih lanjut untuk meningkatkan akurasi dan efisiensi proses ini. Penelitian ini bertujuan untuk memahami dan memperbaiki proses ekstraksi sinyal EKG dan klasifikasi berbasis *Machine Learning* dan *Deep Learning*. Pada dasarnya, penelitian ini bertujuan untuk mengevaluasi dan membandingkan berbagai model, dengan fokus pada model *Random Forest* dan *Convolutional Neural Networks* (CNN). Penelitian ini melakukan tinjauan terhadap beberapa penelitian terkait, khususnya yang berfokus pada proses ekstraksi dan klasifikasi sinyal EKG dengan menggunakan *Machine Learning* dan *Deep Learning*. Setelah ekstraksi dan klasifikasi data, proses evaluasi dan komparasi dilakukan untuk menentukan model dengan performa terbaik. Dari penelitian yang telah dilakukan, ditemukan bahwa metode *Machine Learning* pada umumnya menunjukkan tingkat akurasi antara 97.02% - 99.66%, dengan metode *Random Forest* memiliki akurasi sebesar 97.02%. Sedangkan metode CNN menunjukkan tingkat akurasi yang lebih tinggi, yaitu antara 98.75% - 100%. Dengan demikian, penelitian ini mengkonfirmasi keunggulan CNN dalam proses klasifikasi ini, dan menunjukkan potensi untuk penggunaan lebih lanjut dalam pendeteksian dini penyakit jantung.

**Keywords:** Machine Learning, Deep Learning, Ekstraksi, EKG, Klasifikasi

This work is licensed under Creative Commons Attribution License 4.0 CC-BY International license



### PENDAHULUAN

*Artificial Intelligence* saat ini menjadi salah satu perhatian dunia dikarenakan perkembangannya yang begitu sangat cepat. Seiring berkembangnya teknologi yang sangat cepat, banyak sekali jenis - jenis teknologi yang bermunculan untuk membantu bahkan menggantikan pekerjaan manusia salah satunya di bidang kesehatan. Contoh *Artificial Intelligence* yang sangat populer saat ini adalah *ChatGPT* atau *Generative Pre-training Transformer* yang mampu berinteraksi dengan manusia melalui chat. *ChatGPT* merupakan *Large Language Model* (LLM) yang menggunakan metode *Deep Learning*

untuk dapat menghasilkan teks yang mirip manusia sebagai responnya. *ChatGPT* dirilis pada tanggal 30 November 2022 sebagai pengembangan teknologi terbaru dari OpenAI dari *Large Language Model* yang mampu melakukan percakapan yang cerdas [1]. Selain itu, salah satu cabang *Artificial Intelligence* sederhana dan banyak sekali dijadikan bahan pembelajaran adalah *Machine Learning* dan sampai saat ini masih terus berkembang pesat di kalangan programmer atau khususnya di dunia IT. *Machine Learning* sendiri terdiri atas 2 bagian yaitu *Machine Learning Supervised* dan *Machine Learning Unsupervised*. Sedangkan *Deep Learning*, merupakan kemajuan terbaru dari

kecerdasan buatan yang telah digunakan mengatasi banyak masalah yang melibatkan kumpulan data besar atau *big data*.

*Machine Learning Supervised* adalah struktur dari suatu data yang hendak dianalisis telah ditentukan dahulu dan *Machine Learning* mencari data di struktur tersebut, sedangkan *Machine Learning Unsupervised* struktur dari suatu data dicari oleh *Machine Learning* itu sendiri [2]. Salah satu algoritma *Supervised Learning* yang sering digunakan pada proses klasifikasi adalah algoritma *Random Forest (RF)*. *Random Forest* adalah teknik bagging yang memiliki karakteristik signifikan yang berjalan efisien pada dataset besar. *Random Forest* dapat menangani ribuan variabel masukan tanpa penghapusan variabel dan memperkirakan fitur penting untuk klasifikasi.

Di dalam dunia medis, teknologi - teknologi banyak sekali diterapkan untuk memenuhi kebutuhan medis itu sendiri seperti AI pendeteksi pasien positif Covid atau tidak dengan memanfaatkan hembusan nafas dari pasien tersebut. Dan masih banyak lagi hal - hal yang bisa kita manfaatkan untuk mengembangkan teknologi di bidang kesehatan salah satunya adalah dengan memanfaatkan sinyal EKG atau Elektrokardiogram untuk mengklasifikasi penyakit gagal jantung pada pasien. Laporan WHO menunjukkan bahwa penyakit jantung dan pembuluh darah, atau Cardiovascular Diseases (CVD), menyebabkan 31% kematian global setiap tahun (17,7 juta orang). Di Indonesia, data riset 2018 mencatat bahwa 15 dari 1000 orang (sekitar 2,8 juta individu) menderita penyakit ini, dan angkanya terus meningkat [3]. Salah satu faktor penyebab munculnya penyakit gagal jantung adalah kualitas lingkungan yang tidak sehat [4]. EKG merupakan sebuah informasi sinyal yang digambarkan dalam bentuk diagram yang menampilkan informasi penting mengenai keadaan jantung manusia. Elektrokardiogram atau EKG adalah rekaman aktivitas listrik yang dihasilkan melalui siklus detak jantung [5].

Tujuan dari penelitian ini adalah untuk melakukan perbandingan antara metode tradisional atau *Machine Learning* menggunakan *Random Forest* dengan *Convolutional Neural Network (CNN)* menggunakan arsitektur *ResNet-50*. Hasil dari perbandingan tersebut akan dilakukan pengembangan lebih lanjut untuk meningkatkan hasil akurasi dan ketepatan model dalam melakukan klasifikasi terhadap sinyal EKG. Oleh karena itu, yang menjadi tujuan utama dari *systematic literature review* ini adalah untuk menganalisis dan mendapatkan metode yang terbaik dalam mengklasifikasi sinyal EKG.

## METODE PENELITIAN

Pada penelitian ini, metodologi yang akan digunakan adalah *systematic literature review*. Penelitian ini didasarkan pada beberapa jurnal yang memiliki hubungan dan kaitan dengan klasifikasi *Arrhythmia Database*. Pemilihan jurnal yang akan dipakai untuk dijadikan referensi melalui website *Sciencedirect*, *Google Scholar*, dan *Scopus*.

Peningkatan jumlah studi literatur memungkinkan untuk menerapkan metodologi *systematic literature review*. Metodologi SLR dapat mengurangi pandangan subjektif penulis sehingga dengan menggunakan metode *bibliometric* dan *network analisis*, metode SLR menjadi tren penelitian yang luar biasa dan bisa dilakukan dalam melakukan analisis yang mendalam [6].

### 2.1 Perencanaan Tinjauan Pustaka

Perencanaan untuk mencari paper penelitian terkait memiliki 3 tahapan antara lain: pemilihan keyword, penentuan kriteria, dan pemilihan paper. Masing-masing tahapan akan digambarkan pada gambar sebagai berikut:



Gambar 1. Tahapan Pemilihan Artikel

#### 2.1.1 Penentuan Database

Paper yang akan digunakan dapat dikumpulkan melalui beberapa website yang menyediakan *database* paper antara lain *Sciencedirect*, *Google Scholar*, dan *Scopus*.

#### 2.1.2 Penentuan Keyword atau Kata Kunci

Setelah ditetapkan beberapa website yang akan digunakan untuk mencari paper, maka peneliti perlu menentukan *keyword* atau kata kunci yang akan digunakan dalam mencari paper yang berkaitan dengan penelitian. Salah satu kata kunci yang digunakan dalam mencari paper adalah "*MIT-BIH Arrhythmia*" dan "*Classification ECG*".

#### 2.1.3 Penentuan Kriteria Inklusi dan Eksklusi

Pada saat mencari paper yang sesuai dengan penelitian menggunakan website yang dipilih, peneliti harus membatasi pencarian paper dengan ketentuan batasan 100 paper dengan menerapkan kriteria Inklusi dan Eksklusi pada kumpulan paper tersebut. Kriteria Inklusi merupakan karakteristik umum suatu penelitian yang akan diteliti berdasarkan tujuan dari penelitian tersebut, sedangkan untuk Eksklusi adalah suatu kriteria yang menghilangkan subjek yang tidak memenuhi kriteria dari Inklusi itu sendiri oleh peneliti. Berikut merupakan kriteria dari Inklusi dan Eksklusi adalah:

- A. Paper yang akan dijadikan referensi atau sitasi dalam rentang waktu publish 5 tahun terakhir atau dimulai dari tahun 2018.
  - B. Paper memiliki hubungan atau kaitan dengan apa yang akan dilakukan oleh peneliti.
  - C. Memiliki SJR *value* lebih dari 1.
- Kemudian untuk kriteria dari Eksklusi adalah sebagai berikut:
- A. Tidak dapat diunduh.

## 2.2 Peninjauan Artikel Terpilih

Setelah paper dibatasi dan sudah ditentukan sebanyak 100 paper, selanjutnya dari 100 paper tersebut dilakukan *filterisasi* untuk mendapatkan paper yang sesuai dengan kriteria Inklusi dan Eksklusi sehingga peneliti dapat menentukan 17 paper yang sesuai dengan kriteria dan dikategorikan sebagai penelitian terkait.

## HASIL DAN PEMBAHASAN

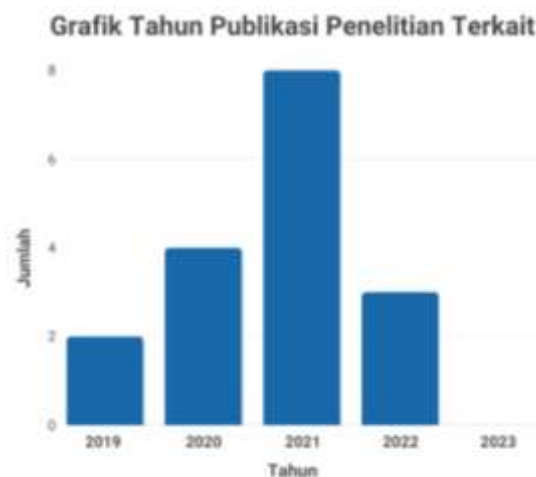
Dari hasil studi literatur yang telah dilakukan, sebelumnya ditetapkan 100 paper untuk ditentukan 17 paper yang akan digunakan sesuai dengan penelitian terkait.

Tabel 1. Ringkasan Paper Penelitian Terpilih

Paper	Penulis	Variabel	Negara	Tahun
[7]	H. Almutairi et al.	<i>Sleep Apnoea</i>	<i>Other</i>	2021
[8]	P. Kanani & M. Padole	<i>Arrhythmia</i>	<i>Other</i>	2020
[9]	D. K. Atal & M. Singh	<i>Arrhythmia</i>	<i>Other</i>	2020
[10]	S. Mandal et al.	<i>Ventricular Arrhythmia</i>	<i>Other</i>	2021
[11]	R. K. Tripathy et al.	<i>Congestive Heart Failure</i>	<i>Other</i>	2019
[12]	J. Rahul et al.	<i>Arrhythmia</i>	<i>Other</i>	2021
[13]	S. Sowmya & D. Jose	<i>Arrhythmia</i>	<i>Other</i>	2022
[14]	Y.-Y. Jo et al.	<i>Arrhythmia</i>	<i>Other</i>	2021
[15]	L. Zheng et al.	<i>Arrhythmia</i>	<i>Other</i>	2021
[16]	S. C. Mohonta et al.	<i>Arrhythmia</i>	<i>Other</i>	2022
[17]	K. Prashant et al.	<i>Arrhythmia</i>	<i>Other</i>	2022
[18]	V. Jahmunah et al.	<i>Coronary Artery, Myocardial Infarction &amp;</i>	<i>Other</i>	2021

Paper	Penulis	Variabel	Negara	Tahun
		<i>Congestive Heart Failure</i>		
[19]	A. S. Eltrass et al.	<i>Congestive Heart Failure &amp; Arrhythmia</i>	<i>Other</i>	2020
[20]	A. A. Bhurane et al.	<i>Congestive Heart Failure</i>	<i>Other</i>	2019
[21]	M. Porumb et al.	<i>Congestive Heart Failure</i>	<i>Other</i>	2020
[22]	A. Rath et al.	<i>Heart Disease</i>	<i>Other</i>	2021
[23]	A. Pal et al.	<i>Arrhythmia</i>	<i>Other</i>	2021

Pada Tabel 1 telah dilakukan pengelompokan penelitian terkait berdasarkan penelitian yang akan dilakukan. Dari ringkasan penelitian tersebut, peneliti telah membuat sebuah grafik untuk menggambarkan jumlah tahun publikasi dari kumpulan penelitian pada Gambar 2.



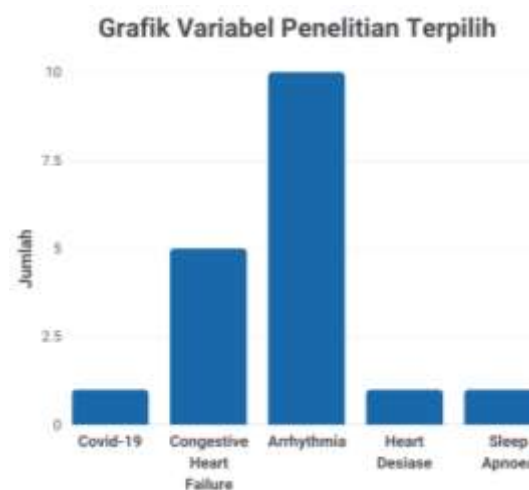
Gambar 2. Grafik Tahun Publikasi

Untuk lebih memahami paper-paper yang telah dikelompokkan, peneliti akan memaparkan *variable* yang digunakan pada penelitian terkait yaitu model dan hasil evaluasi model dari paper penelitian terkait. Selain itu, peneliti juga mencari tahu model mana yang memiliki hasil evaluasi terbaik diantara model lainnya pada penelitian terkait. Peneliti telah merangkum detail dari penelitian terkait beserta model dan hasil evaluasinya pada Tabel 2.

Tabel 2. Evaluasi Model

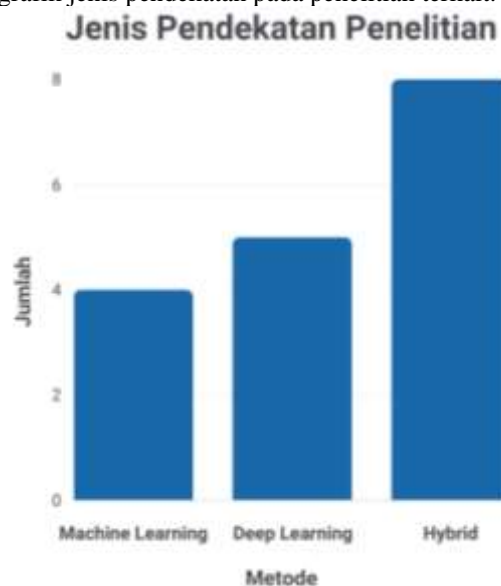
Paper	Model	Pendekatan	Akurasi
[7]	<i>CNN &amp; LSTM</i>	<i>Hybrid</i>	94.27%
[8]	<i>Time-Series &amp; DL</i>	<i>Hybrid</i>	99.12%
[9]	<i>CNN &amp; BaROA</i>	<i>Hybrid</i>	93.19%
[10]	<i>RF</i>	<i>Machine Learning</i>	97.02%
[11]	<i>HCMM</i>	<i>Machine Learning</i>	98.78%
[12]	<i>SVM</i>	<i>Machine Learning</i>	99.51%
[13]	<i>CNN &amp; LSTM</i>	<i>Hybrid</i>	99.7%
[14]	<i>XDM</i>	<i>Deep Learning</i>	-
[15]	<i>CNN &amp; SVM</i>	<i>Hybrid</i>	96%
[16]	<i>CWT &amp; CNN</i>	<i>Hybrid</i>	99.65%
[17]	<i>CNN &amp; OWAE</i>	<i>Hybrid</i>	95.29%
[18]	<i>GabornCNN</i>	<i>Deep Learning</i>	98.74%
[19]	<i>CNN &amp; CQ-NSGT</i>	<i>Hybrid</i>	98.82%
[20]	<i>QSVM</i>	<i>Machine Learning</i>	99.66%
[21]	<i>CNN</i>	<i>Deep Learning</i>	100%
[22]	<i>GAN-LSTM</i>	<i>Deep Learning</i>	99.4%
[23]	<i>CNN</i>	<i>Deep Learning</i>	98.92%

Setelah dilakukan pengelompokan penelitian terkait, peneliti telah menggambarkan melalui grafik mengenai *variable* dalam penelitian terkait tersebut pada Gambar 2, untuk pendekatan pada penelitian terkait akan digambarkan pada Gambar 3, serta sumber data yang digunakan akan digambarkan pada Gambar 4.



Gambar 3. Grafik Variabel Penelitian

Pengelompokan variabel pada penelitian terkait untuk menentukan variabel mana yang banyak digunakan untuk proses klasifikasi tersebut. Selanjutnya adalah dengan menentukan jenis pendekatan yang digunakan dalam proses klasifikasi dengan masing - masing model yang akan digunakan. Gambar 4 akan menampilkan grafik jenis pendekatan pada penelitian terkait.



Gambar 4. Grafik Jenis Pendekatan Penelitian

Berdasarkan jenis pendekatan yang digambarkan pada grafik diatas, pendekatan yang banyak digunakan adalah *Hybrid* dengan total 8 penelitian terkait. Pada Tabel 2, untuk menjawab pertanyaan di awal model yang memiliki performa paling baik dan stabil adalah *Convolutional Neural Network (CNN)* dengan mengevaluasi model yang paling banyak digunakan adalah Akurasi model tersebut.

Adapun teori - teori yang akan digunakan dalam penelitian ini untuk membangun model dan



dilakukannya suatu perbandingan antara metode tradisional atau *Machine Learning* menggunakan *Random Forest* dengan *Convolutional Neural Network (CNN)* menggunakan arsitektur ResNet-50 adalah sebagai berikut:

### 3.1 MIT-BIH Arrhythmia Database

*MIT-BIH Arrhythmia Database* adalah rangkaian uji standar yang umumnya tersedia untuk mengevaluasi aritmia deteksi. Sejak 1980, basis data ini telah digunakan untuk dasar penelitian untuk dinamika jantung di sekitar 500 lokasi di seluruh dunia. Basis data ini sebagian besar digunakan untuk tujuan medis dan penelitian dari deteksi dan analisis aritmia jantung yang berbeda. Basis data ini mencoba menyediakan informasi yang tepat untuk mendeteksi aritmia ventrikel [24].

Aritmia adalah perubahan detak jantung yang tidak normal karena detak jantung yang tidak tepat yang menyebabkan kegagalan dalam pemompaan darah. Aritmia dapat menyebabkan kematian jantung mendadak. Gejala aritmia yang umum adalah denyut prematur, jantung berdebar, pusing, kelelahan, dan pingsan. Aritmia lebih sering terjadi pada orang yang menderita tekanan darah tinggi, diabetes dan arteri koroner penyakit [25]. Sinyal Elektrokardiogram yang akan digunakan pada penelitian ini diambil dari *MIT-BIH Arrhythmia Database*.

### 3.2 Elektrokardiogram (EKG)

Elektrokardiogram (EKG) adalah tes medis yang mengukur aktivitas listrik jantung. EKG digunakan untuk mendiagnosis dan memantau berbagai kondisi jantung, seperti serangan jantung, aritmia, dan gagal jantung. EKG akan merekam aktivitas listrik kecil yang dihasilkan oleh jantung selama periode waktu tertentu dengan menempatkan elektroda pada tubuh pasien [26]. Rekaman EKG berisi *noise* dan amplitudo yang bervariasi dari setiap orang sehingga sulit dalam proses mendiagnosis [27].

Elektrokardiogram (EKG) memberikan informasi penting tentang berbagai kondisi manusia [28]. Untuk melakukan EKG, petugas kesehatan akan menempelkan tambalan kecil dan lengket yang disebut elektroda ke dada, lengan, dan kaki pasien. Elektroda terhubung ke mesin EKG, yang merekam sinyal listrik yang dihasilkan oleh jantung saat bergerak ke seluruh tubuh. Mesin tersebut menghasilkan jejak aktivitas listrik jantung, yang disebut strip EKG, yang kemudian diinterpretasikan oleh petugas kesehatan.

*Machine Learning* dapat diterapkan pada analisis data EKG untuk meningkatkan akurasi dan efisiensi diagnosis dan pengobatan. Misalnya, algoritma pembelajaran mesin dapat dilatih untuk mengenali pola dalam data EKG yang

menunjukkan kondisi jantung tertentu. Algoritma ini kemudian dapat digunakan untuk menganalisis data EKG secara otomatis dan memberikan rekomendasi diagnosis atau pengobatan. Algoritma pembelajaran mesin dapat dilatih untuk mengklasifikasikan data EKG ke dalam kategori yang berbeda, seperti normal atau abnormal, atau untuk mengidentifikasi kondisi jantung tertentu.

Biasanya, klasifikasi sinyal EKG memiliki empat fase: *preprocessing*, segmentasi, ekstraksi fitur, dan klasifikasi. Fase *preprocessing* terutama ditujukan untuk mendeteksi dan melemahkan frekuensi sinyal EKG yang terkait dengan artefak, yang juga biasanya melakukan normalisasi dan peningkatan sinyal. Setelah *preprocessing*, segmentasi akan membagi sinyal menjadi segmen yang lebih kecil, yang dapat mengekspresikan aktivitas listrik jantung dengan lebih baik [27].

### 3.3 Machine Learning

Pembelajaran Mesin atau *Machine Learning* merupakan kemajuan teknologi yang penting karena dapat membantu dalam mengambil keputusan dengan mekanisme prediksi dan klasifikasi berdasarkan data yang ada [29]. Berfokus pada *performance* yang tinggi, teknik pembelajaran mesin atau *machine learning* diterapkan pada bisnis dengan data yang berkembang pesat. Karena pendekatan desain cocok untuk komunikasi komputasi paralel dan terdistribusi yang berevolusi atau data bisnis yang dinamis dan berkembang kedalam model *Machine Learning* [30].

Teknologi berbasis komputer modern banyak yang telah menggunakan Pembelajaran Mesin atau *Machine Learning*. *Machine Learning* merupakan cabang dari Kecerdasan Buatan atau *Artificial Intelligence* yang luas dan sudah berkembang pesat saat ini yang memungkinkan komputer untuk belajar dan berkembang secara otomatis tanpa harus diprogram secara eksplisit. Teknologi ini berasal dari mempelajari pengenalan pola dan teori pembelajaran komputasi. Secara umum, metode pembelajaran yang umum digunakan oleh *Machine Learning* dapat diklasifikasikan menjadi *Supervised*, *Unsupervised*, dan *Reinforcement Learning* [31].

#### 3.3.1 Supervised Learning

*Supervised Learning* merupakan metode *Machine Learning* untuk menyimpulkan fungsi dari data *train*. Algoritma *Supervised Learning* biasanya berisi kumpulan sampel *input (feature)* dan label yang berkaitan dengan kumpulan data tersebut. Tujuan dari pengklasifikasian adalah untuk menemukan batas yang sesuai yang dapat memprediksi label yang benar pada data *test*. Secara singkat, dalam *Supervised Learning*

memiliki setiap contoh data yang berpasangan yang terdiri dari objek masukan (*input*) dan objek keluaran (*output*) yang diinginkan. Algoritma *Supervised Learning* menganalisis data *train* dan menghasilkan fungsi (*model*) [32]. Salah satu contoh metode algoritma pada *Supervised Learning* adalah *Random Forest*.

#### 3.3.1.1 Random Forest

*Random Forest* adalah metode *Machine Learning* yang diperkenalkan pada tahun 2001 oleh Leo Breiman. Metode ini menggunakan serangkaian besar dari *Decision Tree* dengan korelasi timbal balik yang rendah dan fitur yang dipilih secara acak menggunakan metode *bagging* (*Bootstrap AGGREGatING*) [33].

*Random Forest* merupakan salah satu metode pengklasifikasian terbaik dan banyak digunakan untuk regresi dan juga klasifikasi. *Random Forest* memiliki algoritma yang sederhana sehingga menjadi salah satu pilihan yang menarik untuk mengklasifikasi teks. Selain itu, *Random Forest* juga memiliki kemampuan untuk mengolah data berdimensi tinggi dan memiliki performa yang tinggi walaupun menggunakan data yang banyak sehingga menjadi salah satu keuntungan menggunakan model ini dibandingkan dengan model *Machine Learning* lainnya [33].

Pemilihan model ini didasarkan karena pada faktanya bahwa *Random Forest* secara luas dianggap sebagai salah satu metode *Machine Learning* yang paling sukses dan banyak digunakan hingga saat ini [34].

#### 3.4 Deep Learning

*Deep Learning* merupakan kemajuan terbaru dari kecerdasan buatan yang telah digunakan mengatasi banyak masalah yang melibatkan kumpulan data besar atau *big data*. *Deep Learning* juga muncul sebagai alat yang menjanjikan untuk analisis data *scRNA-seq*, karena memiliki kapasitas untuk mengekstrak fitur informatif dan ringkas data *scRNA-seq* yang berisik, heterogen, dan berdimensi tinggi untuk meningkatkan analisis hilir [35].

##### 3.4.1 Convolutional Neural Network (CNN)

*Convolutional Neural Networks (CNNs)*, telah berhasil digunakan untuk memproses dan menganalisa gambar digital, termasuk berbagai jenis gambar medis, termasuk CT. Meskipun beberapa karya telah mempresentasikan hasil menggunakan gambar sinar-X, CT scan cenderung lebih efisien karena dua alasan. Pertama, CT scan memberikan tampilan 3 dimensi yang mendetail dari organ yang didiagnosis, sedangkan sinar-X memberikan tampilan 2-D. Kedua, CT scan tidak tumpang tindih dengan organ, sedangkan pada

sinar-X, tulang rusuk tumpang tindih dengan paru-paru dan jantung [36].

#### SIMPULAN

Dari hasil pencarian *keyword* pada beberapa platform atau website jurnal dan telah dibatasi sebanyak 100 paper dengan kriteria Inklusi dan Eksklusi yang diterapkan sehingga mendapatkan 17 paper yang masuk kedalam kategori atau kriteria tersebut. Untuk menjawab pertanyaan sebelumnya yaitu model yang memiliki hasil atau akurasi terbaik serta stabil adalah *Convolutional Neural Network (CNN)* dengan tingkat akurasi rata - rata 98.75% - 100%. Untuk teknik evaluasi performa model dalam klasifikasi sinyal EKG menggunakan *confusion matrix* yang terdiri dari Akurasi, Presisi, *Recall*, dan *F1 Score*.

#### DAFTAR PUSTAKA

- [1] D. O. Eke, "Chatgpt and the rise of Generative AI: Threat to academic integrity?," *Journal of Responsible Technology*, vol. 13, p. 100060, 2023. doi:10.1016/j.jrt.2023.100060
- [2] Pojon, M. (2017). *Using machine learning to predict student performance* (Master's thesis).
- [3] I. M. Agus Oka Gunawan, I. D. Indah Saraswati, I. D. Riswana Agung, and I. P. Eka Putra, "Klasifikasi Penyakit jantung menggunakan algoritma decision Tree Series C4.5 Dengan Rapidminer," *Jurnal Teknologi Dan Sistem Informasi Bisnis*, vol. 5, no. 2, pp. 73–83, 2023. doi:10.47233/jteksis.v5i2.775
- [4] J. Siswanto, A. A. Qalban, and S. N. Lahay, "Aplikasi Sistem Pakar Klasifikasi Kesehatan Lingkungan Permukiman Dengan metode certainty factors," *Jurnal Teknologi Dan Sistem Informasi Bisnis*, vol. 5, no. 2, pp. 103–112, 2023. doi:10.47233/jteksis.v5i2.787
- [5] R. Ganeshkumar and Dr. YSKumaraswamy, "Investigating cardiac arrhythmia in ECG using Random Forest Classification," *International Journal of Computer Applications*, vol. 37, no. 4, pp. 31–34, 2012. doi:10.5120/4599-6557
- [6] J. J. Kim, H. Jang, and S. Roh, "A systematic literature review on humanitarian logistics using network analysis and Topic modeling," *The Asian Journal of Shipping and Logistics*, vol. 38, no. 4, pp. 263–278, 2022. doi:10.1016/j.ajsl.2022.10.003
- [7] H. Almutairi, G. M. Hassan, and A. Datta, "Classification of obstructive sleep apnoea from single-lead ECG signals using convolutional neural and long short term memory networks," *Biomedical Signal Processing and Control*, vol. 69, p. 102906, 2021. doi:10.1016/j.bspc.2021.102906
- [8] P. Kanani and M. Padole, "ECG Heartbeat arrhythmia classification using time-series augmented signals and Deep Learning Approach," *Procedia Computer Science*, vol. 171, pp. 524–531, 2020. doi:10.1016/j.procs.2020.04.056
- [9] D. K. Atal and M. Singh, "Arrhythmia classification with ECG signals based on the optimization-enabled deep convolutional neural network," *Computer Methods and Programs in Biomedicine*, vol. 196, p. 105607, 2020. doi:10.1016/j.cmpb.2020.105607
- [10] S. Mandal, P. Mondal, and A. H. Roy, "Detection of ventricular arrhythmia by using heart rate variability signal and ECG Beat Image," *Biomedical Signal Processing and Control*, vol. 68, p. 102692, 2021.

- doi:10.1016/j.bspc.2021.102692
- [11] R. K. Tripathy, M. R. A. Paternina, J. G. Arrieta, A. Zamora-Méndez, and G. R. Naik, "Automated detection of congestive heart failure from Electrocardiogram Signal using Stockwell transform and hybrid classification scheme," *Computer Methods and Programs in Biomedicine*, vol. 173, pp. 53–65, 2019. doi:10.1016/j.cmpb.2019.03.008
  - [12] J. Rahul, M. Sora, L. D. Sharma, and V. K. Bohat, "An improved cardiac arrhythmia classification using an RR interval-based approach," *Biocybernetics and Biomedical Engineering*, vol. 41, no. 2, pp. 656–666, 2021. doi:10.1016/j.bbe.2021.04.004
  - [13] S. Sowmya and D. Jose, "Contemplate on ECG signals and classification of arrhythmia signals using CNN-LSTM deep learning model," *Measurement: Sensors*, vol. 24, p. 100558, 2022. doi:10.1016/j.measen.2022.100558
  - [14] Y.-Y. Jo *et al.*, "Detection and classification of arrhythmia using an explainable deep learning model," *Journal of Electrocardiology*, vol. 67, pp. 124–132, 2021. doi:10.1016/j.jelectrocard.2021.06.006
  - [15] L. Zheng, Z. Wang, J. Liang, S. Luo, and S. Tian, "Effective compression and classification of ECG arrhythmia by Singular Value Decomposition," *Biomedical Engineering Advances*, vol. 2, p. 100013, 2021. doi:10.1016/j.bea.2021.100013
  - [16] S. C. Mohonta, M. A. Motin, and D. K. Kumar, "Electrocardiogram based arrhythmia classification using wavelet transform with Deep Learning Model," *SSRN Electronic Journal*, 2022. doi:10.2139/ssrn.4088025
  - [17] K. Prashant, P. Choudhary, T. Agrawal, and E. Kaushik, "Owae-net: COVID-19 detection from ECG images using deep learning and optimized weighted average ensemble technique," *Intelligent Systems with Applications*, vol. 16, p. 200154, 2022. doi:10.1016/j.iswa.2022.200154
  - [18] V. Jahmunah, E. Y. K. Ng, T. R. San, and U. R. Acharya, "Automated detection of coronary artery disease, myocardial infarction and congestive heart failure using GABORCNN model with ECG signals," *Computers in Biology and Medicine*, vol. 134, p. 104457, 2021. doi:10.1016/j.combiomed.2021.104457
  - [19] A. S. Eltrass, M. B. Tayel, and A. I. Ammar, "A new automated CNN deep learning approach for identification of ECG congestive heart failure and arrhythmia using constant-q non-stationary Gabor transform," *Biomedical Signal Processing and Control*, vol. 65, p. 102326, 2021. doi:10.1016/j.bspc.2020.102326
  - [20] A. A. Bhurane, M. Sharma, R. San-Tan, and U. R. Acharya, "An efficient detection of congestive heart failure using frequency localized filter banks for the diagnosis with ECG Signals," *Cognitive Systems Research*, vol. 55, pp. 82–94, 2019. doi:10.1016/j.cogsys.2018.12.017
  - [21] M. Porumb, E. Iadanza, S. Massaro, and L. Pecchia, "A convolutional neural network approach to detect congestive heart failure," *Biomedical Signal Processing and Control*, vol. 55, p. 101597, 2020. doi:10.1016/j.bspc.2019.101597
  - [22] A. Rath, D. Mishra, G. Panda, and S. C. Satapathy, "Heart disease detection using deep learning methods from imbalanced ECG samples," *Biomedical Signal Processing and Control*, vol. 68, p. 102820, 2021. doi:10.1016/j.bspc.2021.102820
  - [23] A. Pal, R. Srivastva, and Y. N. Singh, "CardioNet: An efficient ECG arrhythmia classification system using transfer learning," *Big Data Research*, vol. 26, p. 100271, 2021. doi:10.1016/j.bdr.2021.100271
  - [24] S. Kuila, N. Dhandu, and S. Joardar, "Feature extraction and classification of MIT-BiH Arrhythmia Database," *Lecture Notes in Electrical Engineering*, pp. 417–427, 2019. doi:10.1007/978-981-15-0829-5\_41
  - [25] Z. F. Apandi, R. Ikeura, and S. Hayakawa, "Arrhythmia detection using MIT-BiH Dataset: A Review," *2018 International Conference on Computational Approach in Smart Systems Design and Applications (ICASSDA)*, 2018. doi:10.1109/icassda.2018.8477620
  - [26] T. Li and M. Zhou, "ECG classification using wavelet packet entropy and random forests," *Entropy*, vol. 18, no. 8, p. 285, 2016. doi:10.3390/e18080285
  - [27] R. Ganeshkumar and Dr. YSKumaraswamy, "Investigating cardiac arrhythmia in ECG using Random Forest Classification," *International Journal of Computer Applications*, vol. 37, no. 4, pp. 31–34, 2012. doi:10.5120/4599-6557
  - [28] M. Wasimuddin, K. Elleithy, A.-S. Abuzneid, M. Faezipour, and O. Abuzaghlh, "Stages-based ECG signal analysis from traditional signal processing to machine learning approaches: A survey," *IEEE Access*, vol. 8, pp. 177782–177803, 2020. doi:10.1109/access.2020.3026968
  - [29] N. K. Kamila *et al.*, "Machine learning model design for high performance cloud computing & load balancing resiliency: An innovative approach," *Journal of King Saud University - Computer and Information Sciences*, vol. 34, no. 10, pp. 9991–10009, 2022. doi:10.1016/j.jksuci.2022.10.001
  - [30] C. Renggli, S. Ashkboos, M. Aghagolzadeh, D. Alistarh, and T. Hoefler, "SparCML," *Proceedings of the International Conference for High Performance Computing, Networking, Storage and Analysis*, 2019. doi:10.1145/3295500.3356222
  - [31] H. Bhatt, V. Shah, K. Shah, R. Shah, and M. Shah, "State-of-the-art machine learning techniques for melanoma skin cancer detection and classification: A comprehensive review," *Intelligent Medicine*, 2022. doi:10.1016/j.imed.2022.08.004
  - [32] M. Khanzadeh, S. Chowdhury, M. Marufuzzaman, M. A. Tschopp, and L. Bian, "Porosity prediction: Supervised-learning of thermal history for direct laser deposition," *Journal of Manufacturing Systems*, vol. 47, pp. 69–82, 2018. doi:10.1016/j.jmsy.2018.04.001
  - [33] N. Jalal, A. Mehmood, G. S. Choi, and I. Ashraf, "A novel improved random forest for text classification using feature ranking and optimal number of trees," *Journal of King Saud University - Computer and Information Sciences*, vol. 34, no. 6, pp. 2733–2742, 2022. doi:10.1016/j.jksuci.2022.03.012
  - [34] D. Makariou, P. Barriou, and Y. Chen, "A random forest based approach for predicting spreads in the primary catastrophe bond market," *Insurance: Mathematics and Economics*, vol. 101, pp. 140–162, 2021. doi:10.1016/j.insmatheco.2021.07.003
  - [35] M. Brendel *et al.*, "Application of deep learning on single-cell RNA sequencing data analysis: A Review," *Genomics, Proteomics & Bioinformatics*, vol. 20, no. 5, pp. 814–835, 2022. doi:10.1016/j.gpb.2022.11.011
  - [36] H. Naeem and A. A. Bin-Salem, "A CNN-LSTM network with multi-level feature extraction-based approach for automated detection of coronavirus from CT scan and X-ray images," *Applied Soft Computing*, vol. 113, p. 107918, 2021. doi:10.1016/j.asoc.2021.107918